Fundamentos de Aprendizaje Automático y Reconocimiento de Patrones

Introducción a scikit-learn

Tabla de contenido

Tabla de contenido

¿Qué es scikit-learn?

- Bliblioteca de machine learning de python construida sobre
  - python
  - numpy
  - matplotlib
  - scipy

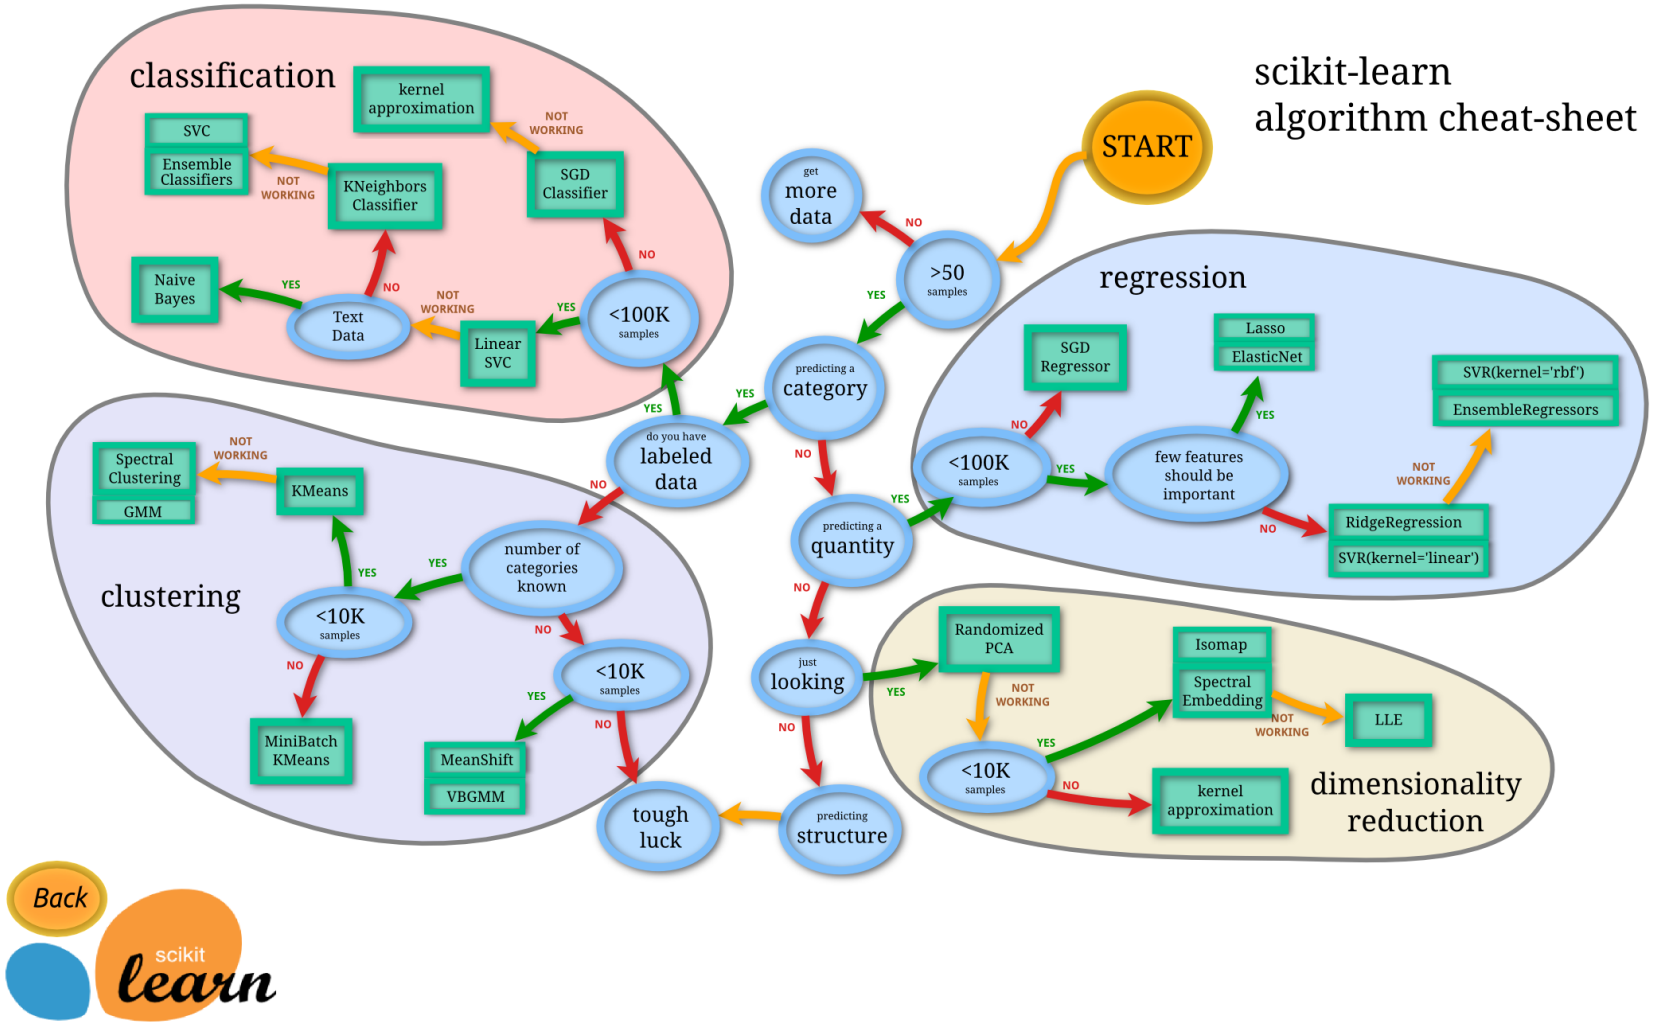

Figure: Estructura de scikit-learn

Tabla de contenido

Datasets

- Scikit-learn viene con algunos conjuntos de datos clásicos de aprendizaje automático
  - base de datos iris
  - dígitos
  - ...
- Además cuenta con una API para bajar otros
  - California housing
  - ...

Base de datos iris

```
from sklearn.datasets import load_iris

data = load_iris()
```

Base de datos iris

```
from sklearn.datasets import load_iris

data = load_iris()
```

```
print(data.keys())

dict_keys(['data', 'target', 'target_names',
           'DESCR', 'feature_names', 'filename'])
```

Base de datos iris

```
from sklearn.datasets import load_iris

data = load_iris()
```

```
print(data.keys())

dict_keys(['data', 'target', 'target_names',
           'DESCR', 'feature_names', 'filename'])
```

```
# Preguntando el valor de la clave
print(data['target_names'])
# Directamente mediante data.
print(data.target_names)
```

Tabla de contenido

División en conjunto de entrenamiento y test

```
# Se importa el modulo que hace
# la division del conjunto
from sklearn.model_selection import train_test_split

# Se realiza la division
X_train, X_test, y_train, y_test = train_test_split(X,
                                   y,random_state=0)
```

Tabla de contenido

Estandarización de los datos

- StandardScaler

```
# Se importa el modulo que hace la transformacion
from sklearn.preprocessing import StandardScaler

# Se encuentran los parametros de estandarizacion
scaler = StandardScaler().fit(X_train)

# Se estandarizan los datos de entrenamiento y test
standardized_X = scaler.transform(X_train)
standardized_X_test = scaler.transform(X_test)
```

Escalado de las características

- MinMaxScaler

```
# Se importa el modulo que hace el escalado
from sklearn.preprocessing import MinMaxScaler

# Se encuentran los parametros de escalado
scaler = MinMaxScaler().fit(X_train)

# Se escalan los datos de entrenamiento y test
scaled_X = scaler.transform(X_train)
scaled_X_test = scaler.transform(X_test)
```

Manejo de datos faltantes

- Imputer

```
# Se importa el modulo que maneja los datos faltantes
from sklearn.preprocessing import Imputer

# Se define la estrategia a seguir en el caso de
                              valores faltantes
imp = Imputer(missing_values=np.nan,
              strategy='mean', axis=0)

# Se rellenan esos valores
X_full = imp.fit_transform(X)
```

PolynomialFeatures

- PolynomialFeatures

```
# Se importa el modulo que hace
# la transformacion polinomica
from sklearn.preprocessing import PolynomialFeatures

# Se define la transformacion a realizar
poly = PolynomialFeatures(5)

# Se realiza la transformacion
Xpoly = poly.fit_transform(X)
```

Tabla de contenido

Regresión lineal

```
# Se importa el modulo
from sklearn.linear_model import LinearRegression

# Se define el clasificador/regresor
lr = LinearRegression()

# Se encuentran los parametros
lr.fit(X, y)

# Se predicen los valores con el conjunto de test
y_pred = lr.predict(X_test)
```

Regresión lineal mediante descenso por gradiente

```
# Se importa el modulo
from sklearn.linear_model import SGDClassifier

# Se define el clasificador/regresor
sgd = SGDClassifier()

# Se encuentran los parametros
sgd.fit(X, y)

# Se predicen los valores con el conjunto de test
y_pred = lr.predict(X_test)
```

Regresión lineal regularizada

```
# Se importa el modulo
from sklearn.linear_model import RidgeClassifier

# Se define el clasificador/regresor
ridge_clf = RidgeClassifier()

# Se encuentran los parametros
ridge_clf.fit(X, y)

# Se predicen los valores con el conjunto de test
y_pred = ridge_clf.predict(X_test)
```

Regresión logística

```
# Se importa el modulo
from sklearn.linear_model import LogisticRegression

# Se define el clasificador/regresor
log_clf = LogisticRegression(solver='sag')

# Se encuentran los parametros
log_clf.fit(X, y)

# Se predicen los valores con el conjunto de test
y_pred = log_clf.predict(X_test)
```

- Una vez que se ejecuta el método *fit* se tiene acceso a los parámetros calculados durante el fit.
- Por ejemplo, en el clasificador de regresión logística se puede acceder a los pesos y al número de iteraciones

```
# se obtienen los pesos
W = log_clf.coef_
# se obtiene el bias
b = log_clf.intercept_
# se obtiene el numero de iteraciones
n_iter = log_clf.n_iter_
```

Ejercicio 1 práctico 5

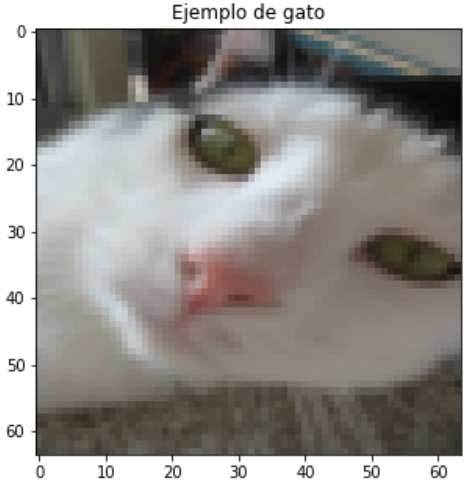

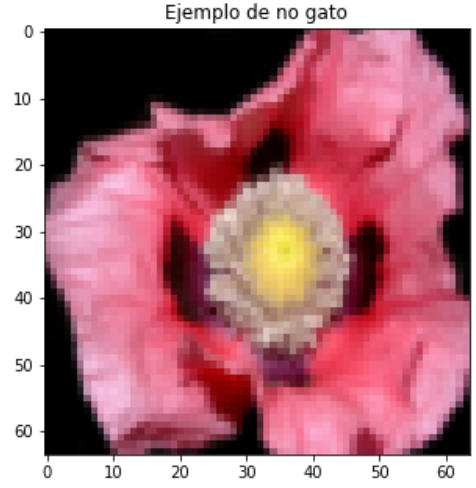

Ejercicio 1 práctico 5

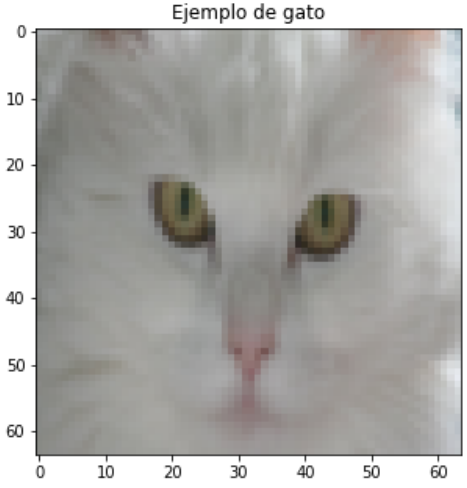

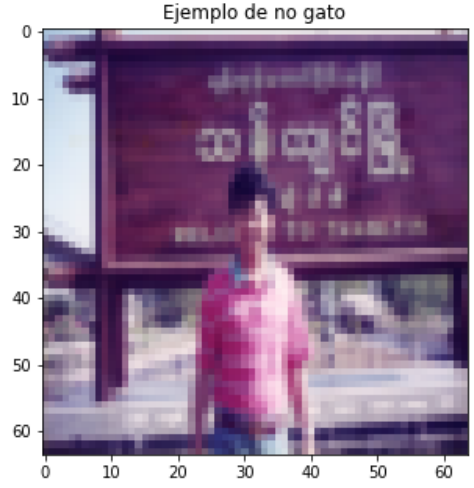

Ejercicio 1 práctico 5

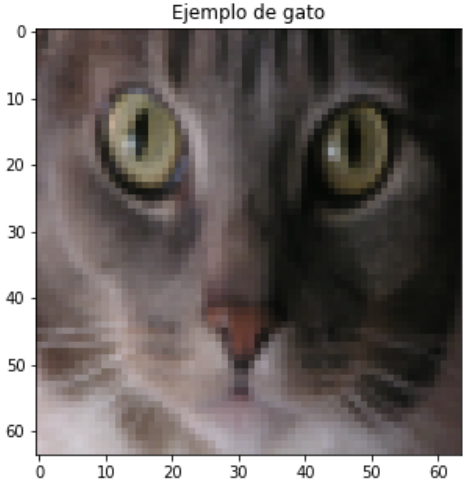

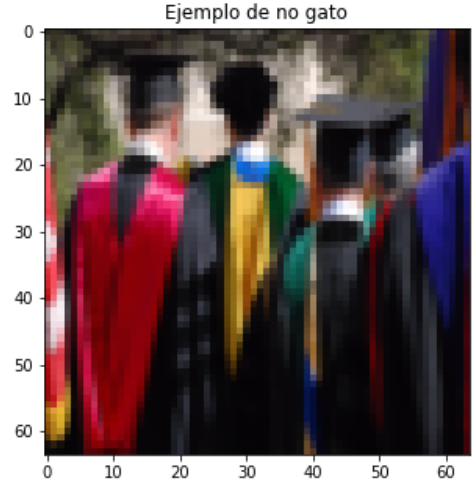

Ejercicio 1 práctico 5

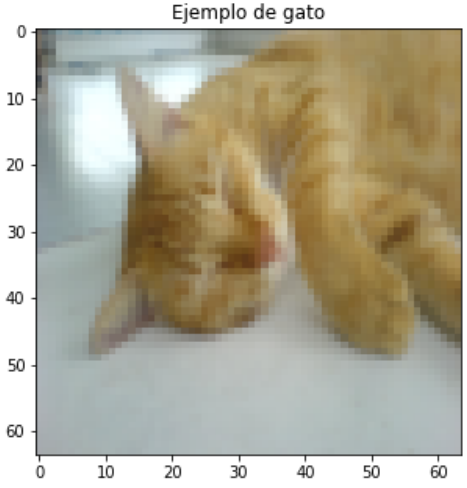

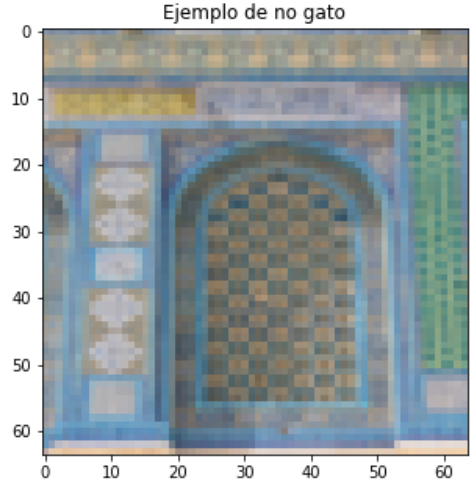

Pesos aprendidos por el modelo logístico

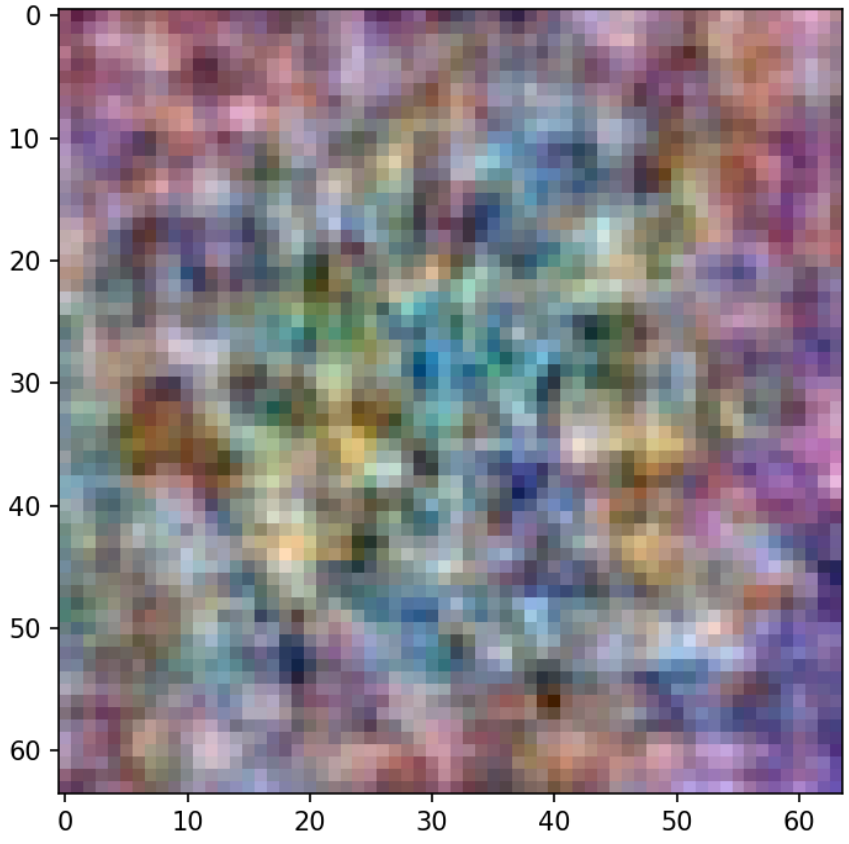

Figure: Pesos aprendidos por el modelo logístico con valores por defecto

Red neuronal

```
# Se importa el modulo
from sklearn.neural_network import MLPClassifier

# Se define el clasificador/regresor
mlp_clf = MLPClassifier(hidden_layer_sizes=(7,),
                activation='relu', max_iter=10000,
                alpha=0, solver='sgd', verbose=10,
                tol=1e-4, random_state=43,
                learning_rate_init=.001)

# Se encuentran los parametros
mlp_clf.fit(X, y)

# Se predicen los valores con el conjunto de test
y_pred = mlp_clf.predict(X_test)
```

Tabla de contenido

Accuracy

- Se puede calcular de dos formas

```
# 1. Utilizando el clasificador
clf.score(X_test, y_test)

# 2. Importando la funcion accuracy_score

from sklearn.metrics import accuracy_score

accuracy_score(y_test, y_pred)
```

Precision-Recall

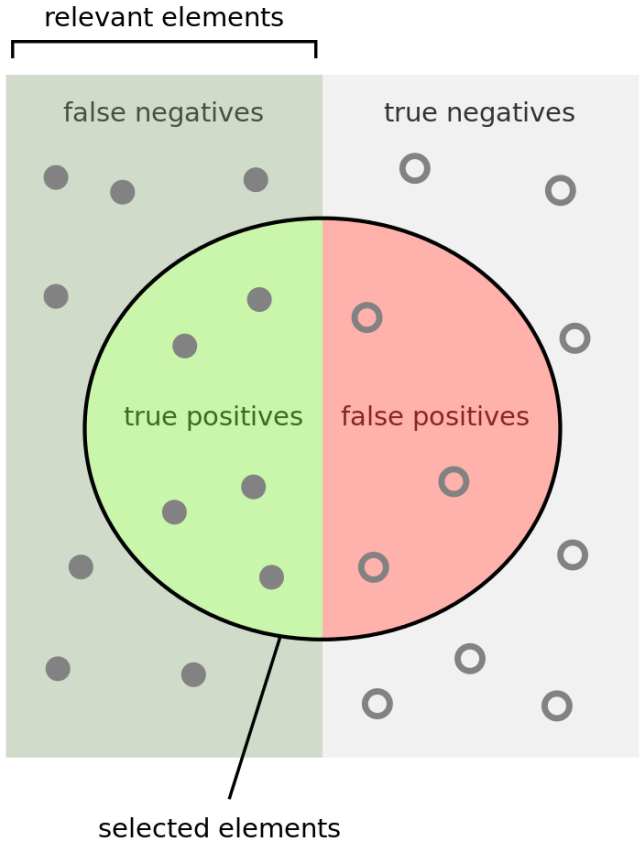

How many selected items are relevant?

$$\text{Precision} = \frac{\text{true positives}}{\text{selected elements}}$$

How many relevant items are selected?

$$\text{Recall} = \frac{\text{true positives}}{\text{relevant elements}}$$

Precision-Recall

- Precision $= VP/(VP + FP)$

```
from sklearn.metrics import precision_score

precision_score(y_test, y_pred)
```

- Recall $= VP/(VP + FN)$

```
from sklearn.metrics import recall_score

recall_score(y_test, y_pred)
```

Ejercicio

Mejorar el desempeño, en términos de *accuracy*, tanto de la **red neuronal de dos capas** como del clasificador que utiliza **regresión logística**. Algunas de las modificaciones que se pueden evaluar son las siguientes:

- Modificación del *learning rate*
- Regularización mediante *weight decay*
- Regularización mediante *early stopping*
- En el caso de la red neuronal, además:
  - Modificación del número de nodos en capa oculta de la red
  - Función de *activación* utilizada
  - Inicialización